



Previsão de rebaixamento no Campeonato Brasileiro Série A

Uma comparação de modelos de machine learning com validação walk-forward

Leonardo Feitosa Barroso

Orientador: Prof. Dr. Hilton Martins de Brito Ramalho

João Pessoa · 2026

Roteiro

01 O problema e a pergunta

02 Dados e método

03 Resultados

04 A prova real: 2025

05 Considerações finais

06 Demonstração do aplicativo

01

O problema e a pergunta

O problema

Cair para a Série B é o pior resultado financeiro possível para um clube

4

clubes rebaixados por temporada

20%

das observações — classe minoritária

3

frentes de receita atingidas: TV, patrocínio e elenco

- A queda reduz receitas de transmissão e patrocínio e deprecia o valor do elenco.
- Os efeitos se estendem por **várias temporadas** após o rebaixamento.
- A antecipação do risco viabiliza decisão de gestão: contratações, renegociação e orçamento.

A pergunta de pesquisa

É possível estimar quem cai *antes de a bola rolar*?

O QUE EXISTE

A literatura foca em **resultado de partidas** e em **ligas europeias**.

A LACUNA

Não foi localizado trabalho sobre rebaixamento no Brasileirão com **apenas informação pré-temporada**.

POR QUE IMPORTA

É o único cenário em que a previsão **serve para decidir algo**.

02

Dados e método

Os dados

Transfermarkt e tabelas oficiais · raspagem automatizada de dados públicos, uso acadêmico

220

observações rotuladas (2014–2024)

15

variáveis preditoras

2025

temporada reservada para prever

3 variáveis de elenco

o que o clube tem

- valor de mercado do elenco
- tamanho do plantel
- número de estrangeiros

12 variáveis de janela deslizante

o que o clube fez

- médias de 3 e de 5 temporadas
- pontos, saldo de gols, gols pró e contra
- vitórias e aproveitamento

Tratamento dos dados

O dado bruto não vinha pronto — a limpeza foi parte do método

O problema dos nomes

As duas páginas do Transfermarkt grafam o mesmo clube de formas diferentes — sem padronizar, o cruzamento falha:

Clube Atletico Paranaense	→	Athletico Paranaense
Athletico-PR	→	Athletico Paranaense
CR Vasco da Gama	→	Vasco da Gama
RB Bragantino	→	Bragantino
Gremio FBPA	→	Gremio

Dicionário de **normalização** com ~60 entradas + remoção de acentos: cruzamento por Clube + Temporada íntegro.

As outras etapas

Valores monetários

remoção de “€”, “mi.”, “mil” e troca de vírgula por ponto

Variável-alvo

lista de rebaixados conferida ano a ano; o restante marcado como permanência

Auditoria do cruzamento

checagem de registros com pontos ausentes para detectar merge falho

Valores faltantes

recém-promovidos não têm histórico — imputação pela mediana do treino (15,5% das janelas)

Escala

padronização ajustada apenas no conjunto de treino

220 observações limpas e auditadas — 11 temporadas × 20 clubes, sem falha no cruzamento.

O método

Um fio condutor: nenhuma informação do futuro entra no modelo


01	02	03	04	05	06
Coleta	Janelas	Imputação e padronização	Validação	Hiperparâmetros	Teste
Transfermarkt	<code>shift(1).rolling()</code>	só no treino	walk-forward	RandomizedSearchCV	2023–2024

As médias da temporada T usam apenas $T-1$ a $T-w$. Nunca a própria temporada prevista.

Por que não a validação cruzada tradicional?

k-fold embaralhado

2014 → 2024, ordem embaralhada




Treina com temporadas **futuras** para prever o passado.

Otimista e irreal.

Walk-forward (janela expansiva)

■ treino ■ validação




Sempre treina no passado e valida no ano seguinte — **5 partições temporais**.

03

Resultados

Estabilidade ao longo das temporadas

AUC-ROC em cada temporada de validação — 5 partições do walk-forward



MÉDIA ± DESVIO NO WALK-FORWARD

— Reg. Logística 0,794 ± 0,058

— Random Forest 0,762 ± 0,071

— LightGBM 0,700 ± 0,151

— XGBoost 0,659 ± 0,085

Teste independente: 2023–2024

40 observações nunca vistas em nenhuma etapa anterior

RANK	MODELO	AUC-ROC	ACURÁCIA
1º	LightGBM	0,877	82,5%
2º	Random Forest	0,844	80,0%
3º	Reg. Logística	0,828	80,0%
4º	XGBoost	0,652	82,5%

Mas o XGBoost tem *a mesma acurácia* do LightGBM: 82,5%.

A armadilha da acurácia

Mesma acurácia, mesma matriz de confusão — AUC muito diferente

POSIÇÃO DOS 8 CLUBES REBAIXADOS NO RANKING DE RISCO PREVISTO (1 = MAIOR RISCO)

LightGBM



AUC 0,877

XGBoost



AUC 0,652

1 • maior risco

40 • menor risco


MATRIZ DE CONFUSÃO — IDÊNTICA NOS DOIS

30 permanências corretas	2 falsos positivos
5 rebaixamentos não previstos	3 rebaixamentos previstos

A acurácia só olha a decisão no limiar. O AUC olha a **ordenação inteira** — e é ela que serve à gestão.

O que pesa no risco

Coefficientes padronizados da Regressão Logística — 8 maiores em módulo



Valor de elenco é a variável dominante — e vitórias recentes protegem.

Sinais entre janelas da mesma métrica devem ser lidos em conjunto: há multicolinearidade entre as médias de 3 e 5 temporadas.

Qual modelo levar para a prática?

LightGBM

MELHOR NO TESTE

- ✓ melhor AUC no teste: **0,877**
- ✗ oscila entre temporadas: **$\pm 0,151$**
- ✗ caixa-preta, sem coeficientes legíveis

Regressão Logística

MODELO ADOADO

- AUC **0,828** — terceira no teste
- ✓ a mais estável: **$\pm 0,058$**
- ✓ coeficientes interpretáveis
- ✓ probabilidades calibradas


Adotou-se a Regressão Logística: *estabilidade e interpretabilidade acima do pico de desempenho.*

04

A prova real: 2025

A previsão para 2025

Regressão Logística treinada em 2014–2024 · 10 maiores riscos, calculados antes da 1ª rodada



A prova real: o campeonato aconteceu

Validação retroativa contra o resultado oficial de 2025

0,922

AUC-ROC realizado na temporada

4 de 4

rebaixados entre os 7 maiores riscos

2 de 4


rebaixamentos previstos no corte de 50%

59/64

pares ordenados corretamente

- Melhor AUC de todos os períodos avaliados — acima do próprio teste (0,828).
- O LightGBM, campeão no teste, caiu para **0,711**: a instabilidade vista no walk-forward se confirmou.
- Supera as heurísticas ingênuas — menor valor de elenco (0,906) e pior média de pontos (0,766).

Previsto × aconteceu



O erro que mais ensina: Mirassol

Um caso atípico — e o tempo tem dado razão ao modelo

43,6%

risco previsto para 2025

4º

posição final em 2025

19º

em 2026, campeonato em curso

- Estreante sem histórico na Série A: as **12 features de janela receberam a mediana do treino**.
- Em 2026 o clube aparece na **zona de rebaixamento** — a fragilidade apontada não desapareceu, apenas demorou uma temporada.

Mirassol é um *outlier*: sem a campanha atípica de 2025, teria caído.

Dez anos de risco em um quadro

Modelo retreinado só com o passado de cada temporada • recorte de 16 clubes

☐ rebaixamento efetivo
 ☐ fora da Série A
 0% 100%

	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
Avaí		79		87			88			
Goiás				62	86		89	83		
Criciúma									77	
Paraná			75							
Atlético-GO		56			88	76	62		72	
Juventude						47	61		83	81
CSA				66						
América Mineiro	29		66			86	66	54		
Sport Recife	39	20	44		92	90				77
Chapecoense	60	37	53	64		80				
Santa Cruz	57									
Cuiabá						70	62	46	41	
São Paulo	5	2	5	3	11	5	16	5	11	16
Corinthians	4	5	12	4	1	0	4	6	7	12
Palmeiras	8	4	3	0	2	1	2	1	1	0
Flamengo	4	2	9	0	1	0	1	0	1	0

05

Considerações finais

Retomada dos objetivos específicos

✓	(i)	Construir a base histórica 2014–2025 com elenco e desempenho	220 observações rotuladas + 2025 para prever
✓	(ii)	Engenharia de features com janelas, sem vazamento temporal	<code>shift(1).rolling()</code> ; imputação e escala só no treino
✓	(iii)	Treinar e otimizar quatro algoritmos com validação temporal	walk-forward de 5 partições + RandomizedSearchCV
✓	(iv)	Comparar em teste independente com métrica adequada	AUC-ROC em 2023–2024; LightGBM 0,877, Logística 0,828
✓	(v)	Aplicar o modelo final à previsão de 2025	e validá-la contra o resultado oficial: AUC 0,922

O objetivo geral foi alcançado.

Contribuições

01

Pipeline reprodutível e sem vazamento temporal

Código, dados e experimentos em repositório público, com semente fixa e separação temporal estrita.

02

Demonstração empírica da armadilha da acurácia

Mesma acurácia e mesma matriz de confusão, com AUC de 0,652 contra 0,877.

03

Histórico recente complementa o indicador financeiro

Elenco e desempenho carregam informação parcialmente distinta sobre o risco.

04

Uma previsão verificada contra a realidade

Não apenas prometida — 4 de 4 rebaixados entre os 7 maiores riscos, AUC de 0,922.

Limitações e próximos passos

Limitações

Só dados pré-temporada: não capta lesão, troca de técnico ou calendário.

~220 observações — amostra pequena aumenta a variância das estimativas.

Recém-promovidos dependem da imputação, como o caso do Mirassol mostrou.

Trabalhos futuros

Retreino *durante* a temporada, com atualização a cada rodada.

Features do mercado de transferências (entradas e saídas por janela).

Modelos sequenciais, com mais temporadas de histórico.

Expansão para a Série B e outras ligas.

O modelo previu antes.
O campeonato confirmou a ordenação.

Agora, a ferramenta em funcionamento: demonstração do aplicativo.

Reserva – números de apoio

NÃO APRESENTAR

WALK-FORWARD (MÉDIAS)

Reg. Logística 0,794 ± 0,058

Random Forest 0,762 ± 0,071

LightGBM 0,700 ± 0,151

XGBoost 0,659 ± 0,085

CALIBRAÇÃO (QUARTIL DE MAIOR RISCO)

previsto 63,6% · observado 50,0%

OTIMIZAÇÃO

RandomizedSearchCV, 30 candidatos, TimeSeriesSplit
de 5 folds, critério AUC

FOLD 2020 (PANDEMIA)

LightGBM 0,438

XGBoost 0,531

Reg. Logística 0,703

BASE

220 obs. rotuladas · 20% de prevalência · 15,5% de
ausentes nas janelas · elenco: média €55,3M · DP
€38,5M · máx. €214,2M

REBAIXADOS DE 2025

Sport (20º) · Juventude (19º) · Fortaleza (18º) · Ceará
(17º)

TESTE 2023-2024 (XGB = LGBM)

3 acertos entre 8 rebaixados · 2 falsos positivos · 30
acertos de permanência

DESBALANCEAMENTO

class_weight='balanced' (RL, RF, LGBM)

scale_pos_weight=4 (XGBoost)

HEURÍSTICAS INGÊNUAS (2025)

menor valor de elenco 0,906 · pior média de pontos
0,766 · modelo 0,922