



UNIVERSIDADE FEDERAL DA PARAÍBA — CCSA

Bacharelado em Ciência de Dados para Negócios

Previsão de Rebaixamento no Campeonato Brasileiro Série A

Uma comparação de modelos de *Machine Learning*
com validação *walk-forward*

Leonardo Feitosa Barroso

Orientador: Prof. Dr. Hilton Martins de Brito Ramalho

- 1 O problema e a pergunta
- 2 Dados e método
- 3 Resultados

- 4 A prova real: 2025
- 5 Contribuições e limites
- 6 Demonstração do app**

O problema

Cair para a Série B é o pior resultado financeiro possível para um clube

4

clubes rebaixados
por temporada

20%

das observações
— classe minoritária

—

receita de TV,
patrocínio e elenco

- A queda derruba receitas de transmissão, patrocínios e o valor do elenco.
- Os efeitos se arrastam por **várias temporadas**.
- Antecipar o risco permite agir: reforços, renegociação, orçamento.

Dá para estimar quem cai *antes de a bola rolar?*

- A literatura foca em **resultado de partidas** e em **ligas europeias**.
- Não localizei trabalho sobre rebaixamento no Brasileirão usando **apenas informação pré-temporada**.
- É justamente o cenário em que a previsão **serve para decidir algo**.

Busca no Google Scholar e Scopus: (*relegation* OR rebaixamento) AND (*machine learning* OR *prediction*).

Os dados

Transfermarkt, raspagem automatizada · dados públicos, uso acadêmico

220

observações
rotuladas
(2014–2024)

15

variáveis preditoras
(*features*)

2025

temporada
reservada
para prever

3 de elenco (*o que o clube tem*)


- valor de mercado
- tamanho do plantel
- n.º de estrangeiros

12 de janela deslizante (*o que ele fez*)

- médias de 3 e 5 temporadas
- pontos, saldo, gols, vitórias, aproveitamento

O método

Um fio condutor: nenhuma informação do futuro entra no modelo



As médias da temporada T usam só $T - 1$ a $T - w$. Nunca a própria temporada prevista.

Por que não a validação cruzada tradicional?

k-fold embaralhado




2014 → 2024, ordem embaralhada

Treina com temporadas **futuras** para prever o passado.

Otimista e irreal.

Walk-forward (janela expansiva)




treino ■ validação ■

Sempre treina no passado e valida no ano seguinte.

Estabilidade ao longo das temporadas


AUC-ROC em cada temporada de validação — 5 partições



A Regressão Logística é a **mais estável** ($\pm 0,058$); o LightGBM, o **mais volátil** ($\pm 0,151$).

Teste independente: 2023–2024

40 observações nunca vistas em nenhuma etapa anterior



■ **LightGBM 0,877**

■ Random Forest 0,844

■ Reg. Logística 0,828

■ **XGBoost 0,652**


**Mas o XGBoost tem a mesma
acurácia que o LightGBM: 82,5%.**

A armadilha da acurácia

Mesma acurácia, mesma matriz de confusão — AUC muito diferente

■ XGBoost 82,5% → AUC 0,652


■ LightGBM 82,5% → AUC 0,877



A acurácia só olha a decisão no limiar. O AUC olha a **ordenação inteira** — e é ela que serve à gestão.

O que pesa no risco

Coeficientes padronizados da Regressão Logística — 8 maiores em módulo



Valor de elenco é a variável dominante; vitórias recentes protegem.

Qual modelo levar para a prática?

LightGBM

- melhor AUC no teste: **0,877**
- mas oscila entre temporadas: $\pm 0,151$
- caixa-preta


Regressão Logística

- AUC 0,828 — terceira
- **mais estável**: $\pm 0,058$
- coeficientes interpretáveis
- probabilidades calibradas

Escolhi a Regressão Logística: estabilidade e interpretabilidade acima do pico de desempenho.

A previsão para 2025

Regressão Logística treinada em 2014–2024 · 10 maiores riscos



Juventude, Sport Recife, Vitória e Mirassol — os quatro maiores riscos.

A prova real: o campeonato aconteceu

Validação retroativa contra o resultado oficial de 2025

2 de 4

rebaixamentos
previstos no corte

0,922

AUC-ROC realizado
na temporada

4 de 4


rebaixados entre os
7 maiores riscos

59/64

pares ordenados
corretamente

- Melhor AUC de todos os períodos avaliados — acima do teste (0,828).
- O LightGBM, campeão no teste, caiu para **0,711**: a instabilidade vista no *walk-forward* se confirmou.
- Supera as heurísticas ingênuas — menor valor de elenco (0,906) e pior média de pontos (0,766).

Previsto *versus* aconteceu



Os quatro rebaixados reais estão no **topo do ranking**.

O erro que mais ensina: Mirassol

Um caso atípico — e o tempo tem dado razão ao modelo

43,6%

risco previsto
para 2025

4.º

posição final
em 2025

19.º


em 2026,
campeonato
em curso

- Estreante sem histórico na Série A: as 12 *features* de janela receberam a mediana do treino.
- Em 2026 o clube aparece na **zona de rebaixamento** — a fragilidade apontada não desapareceu, apenas demorou uma temporada.

Mirassol é *outlier*: sem a campanha atípica, teria caído.

Dez anos de risco em um quadro

Modelo retreinado só com o passado de cada temporada · recorte de 16 clubes



O “efeito elevador” no topo; os grandes em risco baixo e estável embaixo.

1. Um *pipeline* **reprodutível** e sem vazamento temporal para previsão esportiva no contexto brasileiro.
2. A demonstração empírica da **armadilha da acurácia**: mesma acurácia, AUC de 0,652 contra 0,877.
3. Evidência de que o **histórico recente complementa** os indicadores financeiros de elenco.
4. Uma previsão **verificada contra a realidade** — e não apenas prometida.

Limites e próximos passos

Limitações

- só dados pré-temporada: não capta lesões, troca de técnico, calendário
- ~220 observações — amostra pequena
- recém-promovidos dependem da imputação

Trabalhos futuros

- retreino **durante** a temporada
- *features* do mercado de transferências
- modelos sequenciais, com mais temporadas
- Série B e outras ligas

Sensibilidade: imputação por média em vez de mediana → AUC 0,828 (igual); janelas de 2 e 4 temporadas → 0,836.

**O modelo previu antes.
O campeonato confirmou a ordenação.**

Agora, a ferramenta em funcionamento: demonstração do aplicativo

Código, dados e experimentos: github.com/leonardofeitos4/previsao-tcc

Reserva — números de apoio

***Walk-forward* (médias)**

Reg. Logística $0,794 \pm 0,058$

Random Forest $0,762 \pm 0,071$

LightGBM $0,700 \pm 0,151$

XGBoost $0,659 \pm 0,085$

***Fold* 2020 (pandemia)**

LightGBM 0,438 · XGBoost 0,531 · RL 0,703

Teste 2023–2024 (XGB e LGBM idênticos)

3 acertos entre 8 rebaixados · 2 falsos positivos

30 acertos de permanência

Calibração (quartil de maior risco)

previsto 63,6% · observado 50,0%

Base

220 obs. rotuladas · 20% de prevalência

15,5% de ausentes nas janelas

Elenco: média €55,3M · DP €38,5M · máx. €214,2M

Desbalanceamento

`class_weight='balanced'` (RL, RF, LGBM)

`scale_pos_weight=4` (XGBoost)

Otimização

RandomizedSearchCV, 30 candidatos,

TimeSeriesSplit de 5 *folds*, critério AUC

Rebaixados de 2025

Sport (20.º) · Juventude (19.º)

Fortaleza (18.º) · Ceará (17.º)